


CONTENT MODERATION AGENT SYSTEM

Multi-Agent Content Moderation with LangGraph & Human-in-the-Loop

A practical study in Agentic AI Engineering

Vagner Ferreira

Data Scientist | AI/Data Engineer | LLM & Agentic Systems



Automated Content Moderation Is Not Binary



Comentários ambíguos

Nem todo conteúdo se encaixa claramente em permitido ou não permitido.



Contexto de políticas

A decisão depende de diretrizes da comunidade, não só de palavras-chave.



Risco de decisões automáticas

Agir sozinho sobre conteúdo sensível tem consequências reais.



Necessidade de supervisão humana

Casos ambíguos exigem julgamento humano antes da ação final.




Rastreabilidade

Entender por que uma decisão foi tomada importa tanto quanto a decisão.

Como automatizar o processo sem remover o controle humano?


Project Goal



Automação onde é seguro. Supervisão humana onde existe impacto.

O sistema automatiza análise, pesquisa e recomendação — e reserva a decisão final para um moderador humano.


Multi-Agent Moderation Workflow



O Conditional Routing decide o caminho logo após o Analyzer.

Comentários seguros terminam ali. Só casos problemáticos seguem o pipeline completo.

StateGraph Architecture



• EVIDÊNCIA REAL

.draw_mermaid_png()



AgentState

O núcleo do sistema — contrato de estado que atravessa toda a execução do grafo.



analyzer



policy_researcher



reviewer



executar_acao_final

Grafo real gerado pelo próprio LangGraph — nós, arestas e roteamento condicional exatamente como implementados.

One Responsibility per Agent




Estado atual: o Analyzer usa regras determinísticas (heurísticas/keywords), não um LLM em produção.

Arquitetura pronta para evolução: a interface do agente já permite substituir a lógica por um LLM sem alterar o grafo.

AgentState as Communication Contract



The Analyzer Decides the Path



Menor custo



Menor latência



Fluxo previsível

O routing é uma função explícita e testável, não uma lógica escondida dentro dos agentes.

The Workflow Pauses Before the Final Action

• EVIDÊNCIA REAL

```
(venv) PS C:\Projetos\content-moderation-agent-system> python scripts\human_review_demo.py
=====
CONTENT MODERATION AGENT SYSTEM
=====

Comentário recebido:
Ganhe dinheiro rápido! Clique no meu link externo para receber prêmio.

-----

Executando workflow...

{'analyzer': {'comentario_original': 'Ganhe dinheiro rápido! Clique no meu link externo para receber prêmio.', 'analise_do_agente': 'Comentário classificado como positivo ou neutro.'}}

-----
II HUMAN REVIEW REQUIRED
-----

Estado atual do agente:
{'comentario_original': 'Ganhe dinheiro rápido! Clique no meu link externo para receber prêmio.', 'analise_do_agente': 'Comentário classificado como positivo ou neutro.'}

Decisão humana:
EDIT

Retomando workflow...

Workflow finalizado.
❖ (venv) PS C:\Projetos\content-moderation-agent-system>
```

\$ python scripts/human_review_demo.py




HUMAN REVIEW REQUIRED

O workflow para exatamente antes de executar a ação final. Nenhuma remoção, edição ou aprovação acontece sem revisão humana.

A Workflow That Can Stop and Continue

```
workflow.compile(  
    checkpointer=checkpointer,  
    interrupt_before=["executar_acao_final"],  
)
```

O mesmo thread_id identifica a execução e permite sua retomada.



A interrupção não é um erro. É uma etapa controlada do workflow.

The Moderator Can Edit the Agent's State

• EVIDÊNCIA REAL

```
CONTENT MODERATION AGENT SYSTEM

Comentário recebido:
SPAM!!! Clique no meu link externo agora e ganhe dinheiro rápido.

Thread ID:
1e2e4e95-4e1c-482b-b271-1c4de41f5e60

Executando workflow...

{'analyzer': ...}

{'policy_researcher': ...}

{'reviewer': ...}

{'interrupt': ()}

-----

II HUMAN REVIEW REQUIRED

Estado atual do agente:
{
  ...
}

Decisão humana:
EDIT

Estado atualizado pelo moderador:
{
  ...
}

Retomando workflow...

{'executar_acao_final': ...}

Workflow finalizado.
```

Execução real – estado
antes/depois da decisão

decisao_humana


APPROVE / REJECT / EDIT — a escolha do moderador

observacao_humana

Justificativa opcional escrita pelo moderador

O moderador não apenas aprova ou rejeita — ele pode reescrever campos do estado do agente antes da retomada, usando `graph.update_state()`.

Stateful Execution with SQLite



`thread_id`

- ✓ Persistir o estado
- ✓ Pausar uma execução
- ✓ Recuperar o contexto
- ✓ Registrar decisão humana
- ✓ Retomar posteriormente

Persistir o estado é o que transforma uma pausa em um workflow realmente retomável.

Why LangGraph?

Requirement	LangGraph
Stateful workflow	
Conditional routing	
Interrupt / Resume	
Checkpointing	
Explicit graph	
Testable transitions	

LangGraph não foi utilizado apenas para "chamar agentes".

Foi utilizado para orquestrar um workflow stateful, controlável e retomável.

State → Routing → Interrupt → Persistence

Project Structure

• EVIDÊNCIA REAL

```
SRC
├── content_moderation
│   ├── agents
│   │   ├── analyzer.py
│   │   ├── base.py
│   │   ├── models.py
│   │   ├── policy_researcher.py
│   │   └── reviewer.py
│   ├── graph
│   │   ├── workflow.py
│   │   └── routing.py
│   ├── human_review
│   │   └── interface.py
│   ├── persistence
│   │   └── checkpointer.py
│   ├── runtime
│   │   └── threads.py
│   ├── state
│   │   └── agent_state.py
│   └── tools
```

src/content_moderation/



agents/

Analyzer, Policy Researcher, Reviewer — um arquivo por agente



graph/

workflow.py (StateGraph) e routing.py (roteamento condicional)



state/

agent_state.py — o contrato de comunicação (AgentState)



human_review/

interface.py — checkpoint e intervenção humana



persistence/

checkerpointer.py — SQLite checkpointing



runtime/

threads.py — geração de thread_id por execução

Engineering Through Tests

EVIDÊNCIA REAL

```
(venv) PS C:\Projetos\content-moderation-agent-system> pytest
tests/graph/test_workflow.py::test_workflow_accepts_agent_state PASSED [ 52%]
tests/graph/test_workflow.py::test_workflow_routes_neutral_comment_directly_to_end PASSED [ 54%]
tests/graph/test_workflow.py::test_workflow_routes_problematic_comment_through_all_agents PASSED [ 55%]
tests/graph/test_workflow.py::test_workflow_preserves_original_comment PASSED [ 57%]
tests/human_review/test_human_approval_scenarios.py::test_human_approval_keeps_recommendation PASSED [ 59%]
tests/human_review/test_human_approval_scenarios.py::test_human_rejection_preserves_human_decision PASSED [ 60%]
tests/human_review/test_human_approval_scenarios.py::test_ambiguous_comment_requires_human_decision PASSED [ 62%]
tests/human_review/test_human_approval_scenarios.py::test_human_decision_preserves_original_comment PASSED [ 63%]
tests/human_review/test_human_approval_scenarios.py::test_human_review_produces_complete_final_state PASSED [ 65%]
tests/human_review/test_interface.py::test_display_review_shows_moderation_information PASSED [ 67%]
tests/human_review/test_interface.py::test_request_human_decision_accepts_approval PASSED [ 68%]
tests/human_review/test_interface.py::test_request_human_decision_accepts_rejection PASSED [ 70%]
tests/human_review/test_interface.py::test_request_human_decision_accepts_short_answers PASSED [ 72%]
tests/human_review/test_interface.py::test_request_human_decision_rejects_invalid_input PASSED [ 73%]
tests/human_review/test_interface.py::test_collect_human_review_records_approval PASSED [ 75%]
tests/human_review/test_interface.py::test_collect_human_review_records_rejection PASSED [ 77%]
tests/persistence/test_checkpoint.py::test_checkpoint_database_path_is_configured PASSED [ 78%]
tests/persistence/test_checkpoint.py::test_checkpoint_context_manager_is_available PASSED [ 80%]
tests/persistence/test_checkpoint.py::test_checkpoint_database_directory_is_created PASSED [ 81%]
tests/persistence/test_workflow_checkpoint.py::test_workflow_can_be_compiled_with_sqlite_checkpoint PASSED [ 83%]
tests/persistence/test_workflow_checkpoint.py::test_workflow_persists_execution_state PASSED [ 85%]
tests/runtime/test_threads.py::test_create_thread_id_returns_valid_uid PASSED [ 86%]
tests/runtime/test_threads.py::test_create_thread_id_generates_unique_ids PASSED [ 88%]
tests/runtime/test_threads.py::test_create_thread_config_generates_thread_id PASSED [ 90%]
tests/runtime/test_threads.py::test_create_thread_config_preserves_existing_thread_id PASSED [ 91%]
tests/runtime/test_threads.py::test_different_configs_have_isolated_thread_ids PASSED [ 93%]
tests/runtime/test_threads.py::test_is_valid_thread_id_accepts_valid_uid PASSED [ 95%]
tests/runtime/test_threads.py::test_is_valid_thread_id_rejects_invalid_uid PASSED [ 96%]
tests/runtime/test_threads.py::test_thread_id_can_be_reused_for_resume PASSED [ 98%]
tests/test_project.py::test_project_environment PASSED [100%]

===== 61 passed in 0.71s =====
(venv) PS C:\Projetos\content-moderation-agent-system>
```

\$ pytest


61 / 61

TESTS PASSED

Ruff PASS

Compile PASS

Automated Quality Pipeline



Cada push ou pull request para main executa automaticamente as verificações de qualidade.

`.github/workflows/ci.yml`

Lessons Learned



Shared state simplifica agentes

Um contrato de estado bem definido reduz o acoplamento entre agentes.



Human-in-the-loop é decisão arquitetural

Não é um recurso adicional — é parte do design do grafo desde o início.



Persistência transforma pausa em workflow

Sem checkpointing, uma interrupção seria apenas uma falha.



Agentes especializados são mais evolutivos

Cada agente pode ser testado, trocado ou aprimorado isoladamente.



Routing explícito aumenta previsibilidade

O fluxo de decisão fica visível no grafo, não escondido no código.

CONCLUSÃO

Engineering Reliable Agentic Systems

Este projeto explora como transformar agentes de IA em workflows controláveis, testáveis, persistentes e supervisionados por humanos.

6 agentes e componentes de arquitetura testados isoladamente

61 testes automatizados, 100% passando

1 checkpoint humano antes de cada ação final

Content Moderation Agent System

- ✓ LangGraph
- ✓ Multi-Agent Systems
- ✓ Human-in-the-Loop
- ✓ State Management
- ✓ Checkpointing
- ✓ CI

Vagner Ferreira

Data Scientist | AI/Data Engineer | LLM & Agentic Systems



Vagnerkrig/content-moderation-agent-system